

国内编程大模型能力点评（2026 年 4 月视角）

课程参考材料 — 面向高级研发工程师 聚焦 **2026 年发布**的模型；2025 年模型仅在对比表中保留。所有 benchmark 均为模型方自报数据，不同 scaffold 下成绩差异显著，横向对比需谨慎。

一、MiniMax M2 系列 — SWE-bench SOTA，成本革命

1.1 MiniMax-M2.5（2026 年初）

MoE 架构，~228B 参数，Modified-MIT 开源。2025 年 10 月底至 2026 年初，3.5 个月内连续发布 M2 → M2.1 → M2.5。

核心成绩（编码 Agent 场景）：

Benchmark	M2.5	M2.1	Claude Opus 4.6	GPT-5.2
SWE-bench Verified	80.2%	–	78.9% (Droid)	–
Multi-SWE-Bench	51.3%	–	–	–
SWE-bench (Droid scaffold)	79.7%	–	78.9%	–
SWE-bench (OpenCode scaffold)	76.1%	–	75.9%	–

点评： - **SWE-bench Verified 80.2%，当前全球最高**，超越 Claude Opus 4.6 - 在多个不同 scaffold（Droid / OpenCode）上均一致领先，泛化性强 - 成本革命：\$0.3/M input + \$2.4/M output（Lightning 版），**持续运行 1 小时仅 \$1**（100 TPS），仅为 Opus 的 1/10~1/20 - 22.8 分钟完成 SWE-bench 一个任务（与 Opus 4.6 持平），比 M2.1 快 37% - 10+ 语言（Go/C/C++/TS/Rust/Python/Java 等）200K+ 真实环境 RL 训练 - **Spec-writing 行为自发涌现**：先做架构规划再写代码

1.2 MiniMax-M2.7（最新）

GLM-5.1 benchmark 表中已出现 M2.7 作为对比模型，确认已发布：

Benchmark	M2.7	GLM-5.1	Kimi K2.5	Claude Opus 4.6
SWE-Bench Pro	56.2	58.4	53.8	57.3

Benchmark	M2.7	GLM-5.1	Kimi K2.5	Claude Opus 4.6
NL2Repo	39.8	42.7	32.0	49.8
HLE	28.0	31.0	31.5	36.7

点评： M2.5 之后的又一次迭代，SWE-Bench Pro 56.2%，但具体架构和完整 benchmark 尚待 MiniMax 官方公布。

二、GLM-5 / GLM-5.1（智谱 AI / 清华）— 从 vibe coding 到 agentic engineering

2.1 GLM-5（2026 年 2 月，arXiv:2602.15763）

架构： MoE，**744B 总参 / 40B 激活**（较 GLM-4.5 的 355B/32B 大幅扩展），28.5T token 预训练，DeepSeek Sparse Attention (DSA)，MIT 开源。

自研 **slime** 异步 RL 基础设施，大幅提升 RL 训练效率。

Benchmark	GLM-5	DeepSeek-V3.2	Kimi K2.5	Claude Opus 4.5	Gemini 3 Pro
SWE-bench Verified	77.8%	73.1%	76.8%	80.9%	76.2%
SWE-bench Multilingual	73.3%	70.2%	73.0%	77.5%	65.0%
Terminal-Bench 2.0	56.2	39.3	50.8	59.3	54.2
CyberGym	43.2	17.3	41.3	50.6	39.9
BrowseComp	62.0	51.4	60.6	37.0	37.8

点评： - 开源模型 SWE-bench 77.8%，**开源最高**（发布时） - BrowseComp 62.0 远超 Claude Opus 4.5（37.0），Agent 搜索能力突出 - 从 CodeGeeX4 的 ~71-82% HumanEval 到 SWE-bench 77.8%，智谱实现代际跨越

2.2 GLM-5.1（2026 年 Q1-Q2）

GLM-5 的快速迭代版，聚焦 **agentic engineering**——长时段 Agent 任务中持续优化能力。

关键差异化： 不同于前代模型“用完套路后停滞”，GLM-5.1 能在数百轮工具调用中**持续改进**：分解问题 → 实验 → 读取结果 → 定位阻塞 → 修正策略。

Benchmark	GLM-5.1	GLM-5	Kimi K2.5	Claude Opus 4.6	Gemini 3.1 Pro	GPT-5.4
SWE-Bench Pro	58.4%	55.1%	53.8%	57.3%	54.2%	57.7%
NL2Repo	42.7	35.9	32.0	49.8	33.4	41.3
Terminal-Bench 2.0	63.5	56.2	50.8	65.4	68.5	–
CyberGym	68.7	48.3	41.3	66.6	–	–
BrowseComp	68.0	62.0	60.6	–	–	–
BrowseComp (w/ Context)	79.3	75.9	74.9	84.0	85.9	82.7

点评： - SWE-Bench Pro **58.4%** 全球最高，超越 Claude Opus 4.6（57.3%）和 GPT-5.4（57.7%） - CyberGym **68.7%**，安全攻防 Agent 能力全球前列 - 从 GLM-5 到 5.1 的每个 benchmark 都有显著提升，RL scaling 效果明显 - MIT 开源，支持 vLLM / SGLang / KTransformers 本地部署

三、Kimi K2.5（月之暗面）— 原生多模态 + Agent Swarm

发布： 2026 年 1 月（arXiv:2602.02276），基于 Kimi-K2-Base 续训约 15T 混合视觉 + 文本 token。

架构： MoE，**1T 总参 / 32B 激活**，384 专家选 8，MLA 注意力，256K 上下文，MoonViT 视觉编码器（400M），Modified-MIT 开源。

核心能力

- **原生多模态**：视觉 + 语言预训练，视觉知识 / 跨模态推理 / 视觉 Agent 工具调用
- **Coding with Vision**：从 UI 设计稿、视频流程图直接生成代码
- **Agent Swarm**：自动将复杂任务分解为并行子任务，动态实例化领域专用 Agent

编码 Benchmark（Thinking 模式）

Benchmark	K2.5	GPT-5.2	Claude 4.5 Opus	Gemini 3 Pro	DeepSeek V3.2
SWE-bench Verified	76.8%	80.0%	80.9%	76.2%	73.1%
SWE-bench Pro	50.7%	55.6%	55.4%	–	–
SWE-bench Multilingual	73.0%	72.0%	77.5%	65.0%	70.2%
LiveCodeBench (v6)	85.0	–	82.2	87.4	83.3
Terminal-Bench 2.0	50.8	54.0	59.3	54.2	46.4
CyberGym	41.3	–	50.6	39.9	17.3
PaperBench	63.5	63.7	72.9	–	47.1

点评： - SWE-bench 76.8%，超越 Gemini 3 Pro（76.2%）和 DeepSeek V3.2（73.1%） - LiveCodeBench v6 85.0，超越 Claude 4.5 Opus（82.2）和 DeepSeek V3.2（83.3） - SWE-bench Multilingual 73.0% 超越 GPT-5.2（72.0%），多语言工程能力突出 - 1T/32B 架构与 K2 相同，但续训 15T 多模态数据后全面提升 - Agent Swarm 在 BrowseComp（78.4）和 WideSearch（79.0）上效果显著

四、DeepSeek-V3.2（深度求索）— 确认发布

从 GLM-5 和 Kimi K2.5 的 benchmark 表中多次作为对比模型出现，确认已发布。

Benchmark	V3.2	GLM-5	Kimi K2.5	Claude Opus 4.5
SWE-bench Verified	73.1%	77.8%	76.8%	80.9%
SWE-bench Multilingual	70.2%	73.3%	73.0%	77.5%

Benchmark	V3.2	GLM-5	Kimi K2.5	Claude Opus 4.5
Terminal-Bench 2.0	39.3	56.2	50.8	59.3
LiveCodeBench (v6)	83.3	–	85.0	82.2
CyberGym	17.3	43.2	41.3	50.6
BrowseComp	51.4	62.0	60.6	37.0

点评： - SWE-bench 73.1%，相比 V3-0324 的 ~42% 有巨大飞跃 - LiveCodeBench v6 83.3，竞争力强 - 但 Terminal-Bench（39.3）和 CyberGym（17.3）明显落后，**Agent 长程任务能力仍是短板** - 具体架构参数和技术报告尚未看到完整公开

五、Qwen 系列（阿里通义千问）

5.1 Qwen3.6-Plus（最新）

GLM-5.1 benchmark 表中出现 Qwen3.6-Plus 作为对比模型：

Benchmark	Qwen3.6-Plus	GLM-5.1	Kimi K2.5	Claude Opus 4.6
SWE-Bench Pro	56.6%	58.4%	53.8%	57.3%
Terminal-Bench 2.0	61.6	63.5	50.8	65.4
HLE	28.8	31.0	31.5	36.7
AIME 2026	95.1	95.3	94.5	95.6

点评： Qwen 系列最新迭代，SWE-Bench Pro 56.6%，Terminal-Bench 61.6，表现稳健。具体架构细节待官方公布。

5.2 Qwen3-Coder（2025 年 7 月，背景参考）

MoE，480B/36B 激活，Apache 2.0。SWE-bench Verified 70.0%（已被 2026 年模型全面超越），Aider Polyglot 64.4%。

六、字节跳动（ByteDance）

6.1 Doubao-Coder-o1（豆包编程推理模型，2025 年）

SWE-bench Verified ~62.8%，驱动 TRAE AI IDE。

6.2 Seed-Coder-8B（2025 年中）

Dense 8B，MIT 开源，HumanEval+ ~85.4%。8B 级别 SOTA。“LLMs4LLMs” 数据筛选方法。

字节 2026 年新模型数据暂未在 HF 上找到，如有新发布请补充。

七、SWE-bench Verified 排行榜（2026 年 4 月最新）

排名	模型/系统	解决率	备注
1	MiniMax-M2.5	80.2%	国产 #1，全球 SOTA
2	Claude Opus 4.5/4.6	~80.9%/78.9%	Anthropic（scaffold 差异）
3	GPT-5.2	80.0%	OpenAI
4	GLM-5	77.8%	国产 #2，MIT 开源
5	Kimi K2.5	76.8%	国产 #3，多模态 Agent
6	Gemini 3 Pro	76.2%	Google
7	DeepSeek-V3.2	73.1%	国产 #4
–	Qwen3-Coder (2025)	70.0%	已被 2026 模型超越

注意：SWE-bench 成绩极度依赖 Agent scaffold。MiniMax M2.5 使用 Claude Code 为 scaffold，其他模型使用各自内部框架。同模型换框架可差 5-10 个百分点。

八、SWE-Bench Pro 排行榜（更难的下一代 benchmark）

排名	模型	解决率
1	GLM-5.1	58.4%
2	GPT-5.4	57.7%
3	Claude Opus 4.6	57.3%
4	Qwen3.6-Plus	56.6%
5	MiniMax M2.7	56.2%
6	GLM-5	55.1%
7	Kimi K2.5	53.8%

九、综合对比矩阵（2026 年模型）

模型	架构	总参/激活	SWE-bench Verified	SWE-Bench Pro	LiveCodeBench v6	Terminal-Bench 2.0	CyberGym
MiniMax-M2.5	MoE	~228B	80.2%	–	–	–	–
GLM-5.1	MoE	754B/40B	–	58.4%	–	63.5	68.7
GLM-5	MoE	744B/40B	77.8%	55.1%	–	56.2	48.3
Kimi K2.5	MoE	1T/32B	76.8%	50.7%	85.0	50.8	41.3
DeepSeek-V3.2	MoE	–	73.1%	–	83.3	39.3	17.3
Qwen3.6-Plus	–	–	–	56.6%	–	61.6	–
	MoE	–	–	56.2%	–	–	–

模型	架构	总参/ 激活	SWE- bench Verified	SWE- Bench Pro	LiveCodeBench v6	Terminal- Bench 2.0	CyberGym
MiniMax-M2.7							
Claude Opus 4.6	-	-	~78.9%	57.3%	-	65.4	66.6
Gemini 3.1 Pro	-	-	-	54.2%	-	68.5	-
GPT-5.4	-	-	-	57.7%	-	-	-

十、已退出/停更的国产编程模型

模型	状态	说明
Yi-Coder（零一万物）	已停更	公司转向 AI 应用，大模型训练团队裁撤
CodeGeeX4（智谱旧版）	已被 GLM-5/5.1 取代	从 ~71-82% HumanEval 到 77.8% SWE-bench，代际跨越
Qwen3-Coder	仍可用但已被超越	SWE-bench 70.0% 在 2026 格局中不再领先

十一、核心结论

- 国产模型已全面达到世界前沿：**MiniMax M2.5 SWE-bench 80.2% 全球 SOTA；GLM-5.1 SWE-Bench Pro 58.4% 全球 SOTA；国产模型在多个 benchmark 上首次超越所有闭源模型
- 2026 年竞争格局彻底重塑：**五强并立 — MiniMax（SWE-bench SOTA）、智谱 GLM（SWE-Bench Pro SOTA + 安全攻防）、月之暗面 Kimi（多模态 Agent + LiveCodeBench）、DeepSeek（通用编码）、阿里 Qwen（稳健全面）
- MoE 仍是统一路线：**GLM-5（744B/40B）、Kimi K2.5（1T/32B）、MiniMax M2.5（~228B MoE）、DeepSeek V3.2 — 无一例外

4. **Agentic 能力成为核心分水岭**：2026 的 benchmark 从 HumanEval/MBPP 全面转向 SWE-bench Pro / Terminal-Bench / CyberGym / NL2Repo，测的是**长时段多轮 Agent 工程能力**，不是单次代码生成
5. **成本断崖式下降**：MiniMax M2.5 持续运行 1 小时仅 \$1，是 Claude Opus 的 1/10~1/20。“Intelligence too cheap to meter”正在成为现实
6. **RL scaling 是关键引擎**：GLM-5 用 slime 异步 RL，MiniMax 用 Forge Agent-native RL + CISPO 算法，Kimi K2.5 用 Agent Swarm RL — 都在 Agent 环境中做大规模 RL，这是 2026 年的技术主线
7. **Scaffold 依赖是隐忧**：同一模型在不同 scaffold 下 SWE-bench 可差 5-10 个百分点（MiniMax M2.5 Droid 79.7% vs OpenCode 76.1%），自报 benchmark 需谨慎解读

数据来源：HuggingFace 模型卡（moonshotai/Kimi-K2.5, MiniMaxAI/MiniMax-M2.5, zai-org/GLM-5, zai-org/GLM-5.1），各模型方技术报告 注：MiniMax M2.7、Qwen3.6-Plus 的完整数据来自 GLM-5.1 benchmark 表中的对比列，待各自官方补充完整信息