

蒸馏路线做编码大模型的可行性分析

课程参考材料 — 面向高级研发工程师

一、为什么关注蒸馏？

从零预训练编码大模型的成本在数百万到数千万美元量级，对绝大多数团队不现实。蒸馏提供了“站在巨人肩膀上”的路径：从强模型输出中学习，用远低于预训练的成本获得接近的能力。

2025 年 DeepSeek-R1 的蒸馏实验是这条路线最有说服力的证据。

二、关键论文与项目

2.1 DeepSeek-R1 蒸馏（2025.01） — 最重要参考

论文： DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning (arXiv:2501.12948)

做法： 从 DeepSeek-R1（671B MoE）生成约 **80 万条高质量样本**（数学、代码、科学、逻辑），质量过滤后 SFT 蒸馏到 Qwen2.5 和 Llama3 系列。

模型	HumanEval	LiveCodeBench	Codeforces Elo
DeepSeek-R1 (671B)	~92%	65.9%	2,029 (96.3%)
Distill-Qwen-32B	~90.2%	~57.2%	~1,691
Distill-Qwen-14B	~86.6%	~53.1%	–
Distill-Qwen-7B	~79.9%	~37.6%	–
Distill-Llama-70B	~90%+	~57%+	–
Distill-Llama-8B	~80%+	~39%+	–
OpenAI o1-mini (对比)	~92%	~53.8%	1,820 (93.4%)

最关键发现：小模型上纯蒸馏 > 纯 RL。 Distill-Qwen-32B 在多个基准上超过 o1-mini。蒸馏+RL 组合可进一步提升。

2.2 WizardCoder / Evol-Instruct（微软，2023-2024）

用 Evol-Instruct 让 GPT-4 迭代进化编码问题，再微调 StarCoder/Code Llama。WizardCoder-33B-V1.1 HumanEval 79.9%，一度超越 GPT-3.5-turbo。证明**数据质量 > 数据数量**。

2.3 Qwen-Coder 系列（阿里，2024-2025）

Qwen2.5-Coder（2024）：5.5 万亿 token 代码预训练，多阶段流水线（通用预训练 → 代码继续预训练 → 指令微调）。小模型利用大模型蒸馏。Qwen2.5-Coder-7B 仍是 QLoRA 快速验证的经济选择。

Qwen3-Coder（2025.07）：MoE 480B 总参 / 36B 激活，Apache 2.0 开源。SWE-bench Verified 70.0%，Aider Polyglot 64.4%。虽已被 2026 年模型超越，但作为**开源 teacher 模型**仍有价值——Apache 2.0 许可无蒸馏限制，且 MoE 架构推理成本可控。

2.4 OpenCoder（2024 末）

1.5B / 8B，完全公开训练数据、处理流水线、训练协议。为可复现的代码 LLM 训练树立标杆，可作蒸馏实验 baseline 对照。

2.5 StarCoder2（BigCode / HuggingFace / NVIDIA，2024）

3B / 7B / 15B，The Stack v2（619 种语言，4T+ tokens），15B 约 72,000 A100 GPU 小时。OpenRAIL-M 许可。

三、轨迹蒸馏 — 编码智能体最核心的方向

3.1 为什么必须是轨迹蒸馏？

传统蒸馏关注“给定输入，模仿 teacher 输出”。轨迹蒸馏捕获**完整 agent 行为序列**：

思考 → 工具调用 → 观察结果 → 下一步决策 → ... → 最终结果

编码不是单步任务。要做真正的编码智能体而不是代码补全器，必须做轨迹级蒸馏。

3.2 关键论文

FireAct (Chen et al., Princeton, 2023) - 用 GPT-4 生成 ReAct/CoT/Reflexion 三种推理轨迹，过滤成功样本，微调 Llama-2-13B - 核心发现： - 微调后 Llama-2-13B 匹敌甚至超过 GPT-3.5 prompting - **多方法混合轨迹** > 单一方法 - 模型学会“何时用工具、何时直接回答” - **几百条轨迹就能显著提升性能**（sample efficiency 极高）

Agent LUMOS (AI2, ACL 2024) - 将 agent 任务分解为 Planning / Grounding / Execution 三模块 - 统一数据格式：不同来源轨迹转统一格式训练 - LLaMA-2-7B 达到与 GPT-4 agent 竞争水平 - 启示：**模块化设计 + 统一轨迹格式是小模型 agent 蒸馏的有效策略**

AgentTrek (2025) - 通过引导重放 Web 教程合成 agent 轨迹，方法论可迁移至编码 agent

3.3 轨迹格式对比

格式	优点	缺点	推荐度
完整轨迹	保留中间推理，信号最丰富	可能传播错误步骤	中
仅结果	简洁，只保留成功案例	丢失中间推理过程	低
过滤轨迹	兼顾质量和信号丰富度	需额外过滤管道	最推荐
模块化轨迹	独立训练规划/执行，便于调试	设计更复杂	中高

3.4 开源轨迹数据集

- **OpenHands SWE-bench 轨迹**: `xingyaoww/openhands-swe-bench-trajectories` (HuggingFace)
- **SWE-bench / Verified / Lite**: `princeton-nlp/SWE-bench`
- **Agentless / AutoCodeRover / Moatless Tools** 均有轨迹数据发布

3.5 工具使用能力能否蒸馏？

能力层次	蒸馏效果	备注
代码生成	好（teacher 的 85-95%）	最容易迁移
工具调用 / API 选择	可以	需足够多样的工具使用样本

能力层次	蒸馏效果	备注
多步 agent 行为	难度最大	7B 与 frontier 仍有明显差距

关键瓶颈： 小模型上下文理解和长程规划有限，训练分布外泛化不足。

四、蒸馏 vs SFT vs RL 对比

4.1 定量对比（基于 DeepSeek-R1 论文）

维度	蒸馏 (KD)	SFT	RL (GRPO/PPO)	蒸馏 + RL
数据需求	中 (10K-800K)	高	低（只需 reward）	中
训练稳定性	高	高	低	中
上限	受 teacher 约束	受数据约束	可超越 teacher	最高
代码编写	好	好	很好	最好
Agent 行为	中等	取决于数据	好	最好
成本	中低	中	高	最高
小模型效果	最佳	中	差（不稳定）	好

4.2 蒸馏何时有效 / 失效？

有效： - student $\geq$ 7B，足以表达 teacher 知识 - 任务在训练分布内（标准代码补全、常见 bug 修复） - teacher 数据质量高、多样性好 - 有明确模式需要学习（如 ReAct 格式工具调用）

失效： - 需要超越 teacher（蒸馏有天花板） - 长程推理和复杂规划（大型仓库级 bug 修复） - student 太小（1.5B 在 agent 任务上能力不足） - 训练数据过于单一 - 未见过的编程语言或框架

4.3 数据量需求

任务类型	所需样本量
代码补全/生成	10K-50K
推理增强（CoT 蒸馏）	50K-200K

任务类型	所需样本量
Agent 轨迹蒸馏	1K-10K 条轨迹
工具使用	5K-20K 条含工具调用

五、四种路线全面对比

维度	从零预训练	继续预训练+SFT	纯蒸馏	轨迹 SFT
成本 (7B)	\$500K-\$2M	\$50K-\$200K	\$5K-\$50K	\$2K-\$20K
GPU 需求	数百张 A100, 数月	8-32 张, 数周	1-4 张, 数天	1-2 张, 数小时~天
数据需求	万亿 token	千亿 token	10K-800K 样本	100-10K 轨迹
HumanEval	取决于规模	7B ~70-80%	7B ~80%	取决于 base+轨迹
SWE-bench	-	低	低	最适合
Agent 能力	无	无	弱	强
工具使用	无	无	可教会	原生支持
技术门槛	极高	高	中	中低
天花板	理论最高	受 base 限制	受 teacher 限制	受 teacher+base 限制
适合谁	大公司	中型团队	小团队	高级工程师/小团队
训练周期	3-12 个月	2-8 周	1-7 天	数小时~天

六、实操考量

6.1 硬件需求与成本（QLoRA 微调，最经济路线）

模型规模	GPU 显存	推荐硬件	典型训练成本
7B (LoRA)	16-24 GB	1x A100 40GB	\$2-5

模型规模	GPU 显存	推荐硬件	典型训练成本
7B (全参数)	60-80 GB	2-4x A100 80GB	\$50-200
14B (LoRA)	24-40 GB	1x A100 80GB	\$5-15
32B (LoRA)	40-80 GB	1-2x A100 80GB	\$15-50
32B (全参数)	200+ GB	8x A100 80GB	\$500-2000

QLoRA（4-bit 量化 + LoRA）可以把 7B 训练放到单张 RTX 4090 (24GB) 上。

6.2 数据许可合规（红线）

数据来源	许可状态	可否蒸馏	备注
OpenAI (GPT-4/o1)	ToS 禁止训练竞争模型	不可以	-
Anthropic (Claude)	使用政策限制	不可以	-
Google (Gemini)	类似限制	不可以	-
DeepSeek-R1	MIT 许可	可以	671B MoE，蒸馏标杆
Llama 3.1 (Meta)	社区许可证，鼓励蒸馏	可以	-
Qwen2.5-Coder	Apache 2.0	可以	7B/14B，经济 base
Qwen3-Coder	Apache 2.0	可以	480B/36B MoE，SWE-bench 70%
GLM-5 / GLM-5.1	MIT	可以	744B/40B MoE，SWE-bench 77.8%
MiniMax M2.5	Modified-MIT	可以	~228B MoE，SWE-bench 80.2% SOTA
Kimi K2.5	Modified-MIT	可以	1T/32B MoE，多模态 Agent
StarCoder2	OpenRAIL-M	可以	3B/7B/15B

2025 年起 AI 公司开始部署水印和指纹技术检测蒸馏行为。2026 年国产开源模型爆发，MIT/Apache 2.0 许可的 SWE-bench 70%+ 模型已可自由蒸馏。

6.3 蒸馏 vs API 调用：何时值得？

场景	蒸馏成本	月度 API	盈亏平衡
个人/小团队	\$50-500 一次性	\$50-200/月	1-3 个月
中型团队	\$500-5000 一次性	\$2K-20K/月	1 个月内
离线/隐私部署	\$500-5000 一次性	不可用	立即

七、2025-2026 年重要进展

7.1 2025 年：蒸馏路线确立

- DeepSeek-R1 蒸馏的里程碑意义：**首次大规模证明蒸馏在小模型上优于 RL。800K 样本 SFT “菜谱” 已被广泛复制。
- RLCEF 的兴起：**代码执行反馈作为 RL 奖励信号，比 RLHF 更客观。趋势是蒸馏 SFT 作 warm-up，再用 RLCEF 优化。
- 混合流水线成为主流：**SFT (warm-up) → 蒸馏 (teacher knowledge) → RL (push frontier)
- 开源生态爆发：**HuggingFace agent 轨迹数据集快速增长；SmolAgents、OpenHands 支持小模型 agent；TRL、LLaMA-Factory、Axolotl 支持 LoRA + 蒸馏。

7.2 2026 年：Agent-native RL 与开源 teacher 池爆发

- RL scaling 成为核心引擎：**
 - GLM-5 slime 异步 RL：**大幅提升 RL 训练效率，支持 744B MoE 规模
 - MiniMax Forge Agent-native RL + CISPO 算法：**200K+ 真实环境 RL 训练，spec-writing 行为自发涌现
 - Kimi K2.5 Agent Swarm RL：**多 agent 协同环境中训练，多模态 Agent 能力突破
 - 共同特征：**不是在单步代码生成上做 RL，而是在**长时段 Agent 任务**中做 RL
- MoE 架构统一化：**GLM-5（744B/40B）、Kimi K2.5（1T/32B）、MiniMax M2.5（~228B）、Qwen3-Coder（480B/36B）、DeepSeek V3.2 — 无一例外。MoE 让大规模 teacher 模型推理成本可控，蒸馏实验可行性大增。

3. Benchmark 从单步生成转向 Agent 工程：

- SWE-bench Verified → **SWE-Bench Pro**（多文件、跨模块、长时段任务）
- 新增 Terminal-Bench 2.0、CyberGym、NL2Repo、BrowseComp
- 测的不是“写一个函数”，而是“在数百轮工具调用中持续改进、定位阻塞、修正策略”

4. 开源 teacher 池质量跃升：

- MIT/Apache 2.0 许可的模型已覆盖 SWE-bench 70-80% 区间
- GLM-5（MIT，77.8%）、MiniMax M2.5（Modified-MIT，80.2%）、Qwen3-Coder（Apache 2.0，70%）
- 不再需要依赖闭源模型输出做蒸馏，合规风险大幅降低

5. 成本断崖式下降：MiniMax M2.5 持续运行 1 小时仅 \$1（100 TPS），是 Claude Opus 的 1/10~1/20。“Intelligence too cheap to meter”正在成为现实，蒸馏的经济动机从“省钱”转向“定制化 + 离线部署”。

八、推荐蒸馏实操路线

第一层：快速验证（1-2 天，< \$10）

1. Base: Qwen2.5-Coder-7B-Instruct（经济选择）或 Qwen3-Coder 的小规模变体
2. 收集 50-100 条编码 agent 轨迹（OpenHands 开源数据或自行用开源强模型生成）
3. QLoRA (4-bit) 单张 A100 微调
4. 评估：对比微调前后简单工具调用任务表现

第二层：Agent 行为蒸馏（3-5 天，\$50-200）

1. Base: Qwen2.5-Coder-14B 或 32B
2. Teacher: GLM-5（MIT，SWE-bench 77.8%）或 Qwen3-Coder（Apache 2.0，70%）生成 1K-5K 条 team mode 轨迹
3. 格式：过滤后完整轨迹，含 Agent spawn 时机、SendMessage、多阶段编排
4. 全参数或 LoRA rank=64+
5. 评估：自定义 team mode benchmark

第三层：蒸馏 + RL（进阶，\$500+）

1. 第二层基础上，GRPO/PPO + 代码执行反馈
2. 需搭建代码执行沙箱
3. 可能突破蒸馏天花板

轨迹数据格式建议

```
[System] You are a coding agent with tools: Read, Edit, Bash, Agent...
[User] Fix the bug in authentication module...
[Assistant] <thinking>分析问题...</thinking>
[Tool Call] Read(file="auth.py")
[Tool Result] ...file contents...
[Assistant] <thinking>发现问题在第42行...</thinking>
[Tool Call] Agent(task="Write unit test for auth fix",
tools=["Read", "Edit", "Bash"])
...subagent trajectory...
[Tool Call] Edit(file="auth.py", old="...", new="...")
[Tool Call] Bash(command="pytest tests/test_auth.py")
[Tool Result] All tests passed
[Assistant] Bug fixed. The issue was...
```

九、核心结论

1. **蒸馏可行**，且是小团队构建编码 agent 最现实的路径
2. **必须做轨迹蒸馏**，不是问答蒸馏 — 代码补全能力可预训练获得，agent 行为必须通过轨迹学习
3. **推荐路线**：Qwen2.5-Coder 7B/14B 做 base + GLM-5/Qwen3-Coder 做 teacher + QLoRA，成本 < \$10
4. **合规红线**：不能用 Claude/GPT 输出做商用蒸馏。2026 年 MIT/Apache 2.0 许可的 SWE-bench 70-80% 模型已充足
5. **蒸馏不是终点**：最强方案是“蒸馏 SFT + RL”混合流水线，但纯蒸馏 SFT 足以展示核心概念
6. **2026 新变量**：开源 teacher 池质量跃升（GLM-5 MIT 77.8%、MiniMax M2.5 80.2%），蒸馏天花板显著提高；Agent-native RL 是各家突破 SWE-bench 75%+ 的共同路线，蒸馏 + RL 组合潜力更大

一句话：2025 年 DeepSeek-R1 证明了 800K 样本 SFT 可让 32B 超越 o1-mini；2026 年 GLM-5/MiniMax 证明了 MIT 开源模型已达 SWE-bench 80%——蒸馏的 teacher 质量不再是瓶颈，轨迹格式和 RL 后训练才是。

核心参考：DeepSeek-R1 技术报告 (arXiv:2501.12948), FireAct (Chen et al., 2023), Agent LUMOS (ACL 2024), Qwen2.5-Coder 技术报告, GLM-5 技术报告 (arXiv: 2602.15763), Kimi K2.5 技术报告 (arXiv:2602.02276)